尚硅谷大数据项目之 Spark 实时（分层处理）

（作者：尚硅谷研究院）

版本：V2.0

第 1 章 DWD 到 DWS 层数据处理概要

首先明确的是数据的聚合操作，一律交给 OLAP 来完成，因为 OLAP 数据库的特性都是非常利于数据聚合统计的，可以说这也是 OLAP 的本职工作。

那么在此之前实时计算就要完成一些 OLAP 不是特别方便或者性能并不好的操作，比如 JOIN 操作，比如分组去重(需要开窗)或者复杂的数据计算等等，实际情况还要看 OLAP 的选型。那这些工作可以交由实时计算完成。

从 ODS 到 DWD 层主要负责原始数据的整理拆分，形成一个一个的业务事实 topic。

从 DWD 层到 DWS 层主要负责把单个的业务事实 topic 变为面向统计的事实明细宽表，然后保存到 OLAP 中。

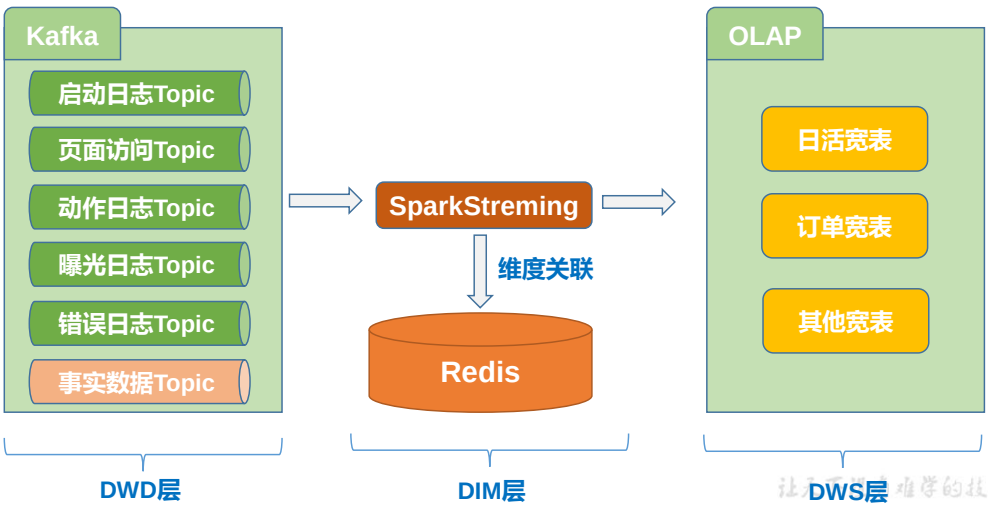

第 2 章 任务:日活宽表

2.1 需求举例

1）当日用户首次登录（日活）分时趋势图

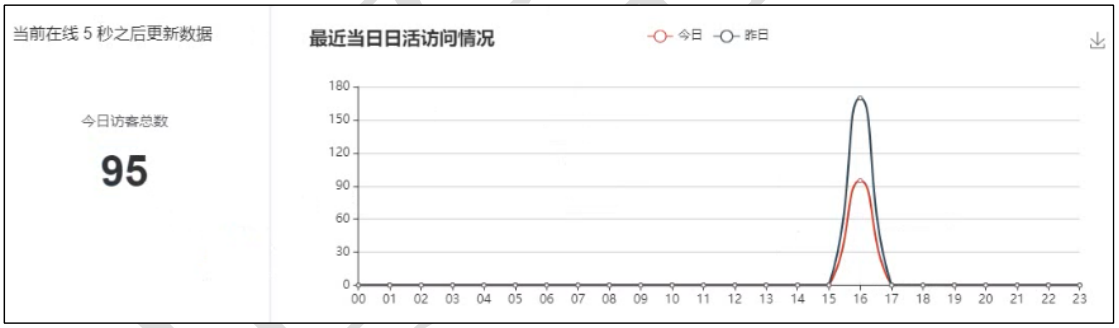

2）不同渠道柱形对比图：

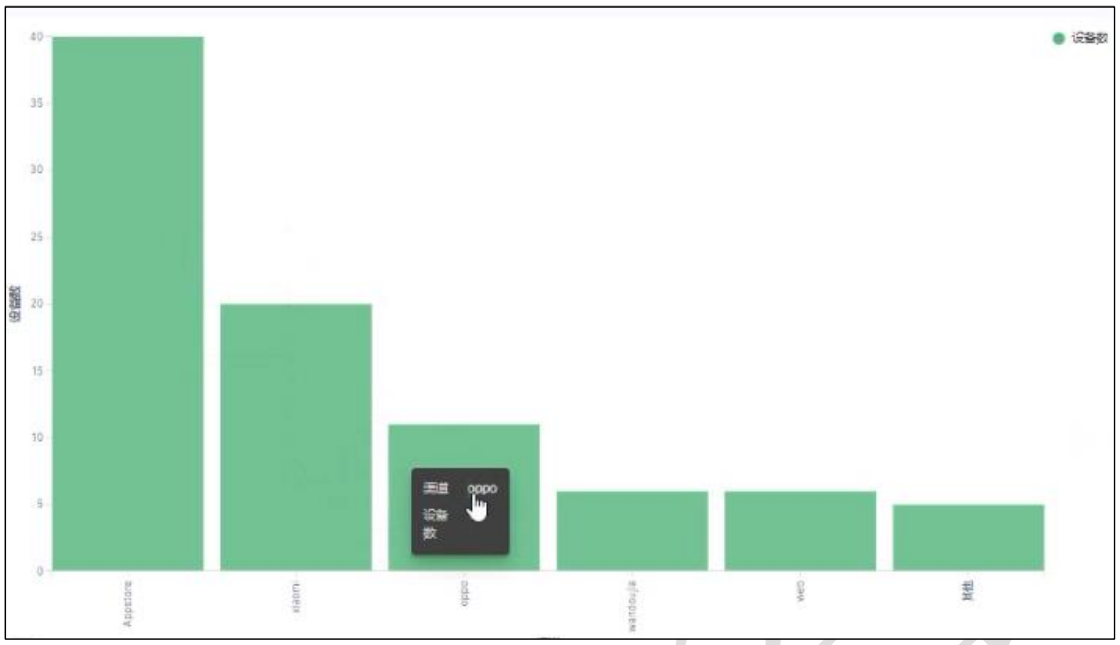

2.2 任务分析

2.2.1 去重

由于日活代表了用户当日的首次访问，因此除了当日的首次访问以外的其他访问，一律需要过滤掉。每个用户每天可能启动多次。要想计算日活，我们只需要把当前用户每天的第一次启动日志获取即可，所以要对启动日志进行去重，相当于做了一次清洗。

实时计算中的去重是一个比较常见的需求，可以有许多方式实现，比如:将状态存在 Redis 中；存在关系型数据库中；通过 Spark 自身的 updateStateByKey（checkPoint 小文件等问题比较麻烦、不方便管理、程序无法变更升级）等

我们这里结合 Redis 实现对当前用户启动日志去重操作

2.2.2 维度关联

由于要针对各种对于不同角度的“日活”分析，而 OLAP 数据库中尽量减少 join 操作，所以在实时计算中要考虑其会被分析的维度，补充响应相应的维度数据，形成宽表。

由于维度数据已经保存在固定容器中了(redis)，所以在实时计算中，维度与事实数据关联并不是通过 join 算子完成。而是在流中查询固定容器来实现维度补充。

2.2.3 输出到 OLAP 中

把清洗和组合好的宽表数据写入到 OLAP 中。这个部分要注意做到尽可能做到：

批量写入：主要是为了减少 IO 次数提高写入性能，同时也能尽可能减少 OLAP 数据内部的小文件的生成。

幂等性写入：为了保证数据的精确一次消费，通过在实时计算中通过控制提交偏移量的位置避免数据丢失，同时通过幂等性的写入避免重复数据。

2.3 功能实现

2.3.1 准备 Bean

```
package com.atguigu.gmall.realtime.bean

case class DauInfo(
                      //基本的页面访问日志的数据
                      var mid :String,
                      var user_id:String,
                      var province_id:String,
                      var channel:String,
                      var is_new:String,
                      var model:String,
                      var operate_system:String,
                      var version_code:String,
                      var page_id:String ,
                      var page_item:String,
                      var page_item_type:String,
                      var during_time:Long,

                      //用户性别 年龄
                      var user_gender : String ,
                      var user_age : String ,

                      //地区信息

                      var province_name : String ,
                      var province_iso_code: String ,
                      var province_3166_2 :String ,
                      var province_area_code : String,

                      //日期
                      var dt : String ,
                      var hr : String ,
                      var ts : Long
                    ){

  def this(){

this(null,null,null,null,null,null,null,null,null,null,null,0L,nu
ll,null,null,null,null,null,null,null,0L)
  }
}
```

2.3.2 准备对象拷贝工具类

```
package com.atguigu.gmall.realtime.util

import java.lang.reflect.{Field, Method, Modifier}

import com.atguigu.gmall.realtime.bean.{DauInfo, PageLog}

import scala.util.control.Breaks

/**
  * 实现对象属性拷贝.
  */
object MyBeanUtils {

  /**
    * 将 srcObj 中属性的值拷贝到 destObj 对应的属性上.
    */
  def copyProperties(srcObj : AnyRef , destObj: AnyRef): Unit ={
    if(srcObj == null || destObj == null ){
      return
    }
    //获取到 srcObj 中所有的属性
    val srcFields: Array[Field] =
srcObj.getClass.getDeclaredFields

    //处理每个属性的拷贝
    for (srcField <- srcFields) {
      Breaks.breakable{
        //get / set
        // Scala 会自动为类中的属性提供 get、 set 方法
        // get : fieldname()
        // set : fieldname_$eq(参数类型)

        //getMethodName
        var getMethodName : String = srcField.getName
        //setMethodName
        var setMethodName : String = srcField.getName+"_$eq"

        //从 srcObj 中获取 get 方法对象，
        val getMethod: Method =
srcObj.getClass.getDeclaredMethod(getMethodName)
        //从 destObj 中获取 set 方法对象
        // String name;
        // getName()
        // setName(String name ){ this.name = name }
        val setMethod: Method =
        try{
          destObj.getClass.getDeclaredMethod(setMethodName,
srcField.getType)
        }catch{
          // NoSuchMethodException
          case ex : Exception =>  Breaks.break()
        }
```

```
        //忽略 val 属性
        val              destField:              Field              =
destObj.getClass.getDeclaredField(srcField.getName)
        if(destField.getModifiers.equals(Modifier.FINAL)){
          Breaks.break()
        }
        //调用 get 方法获取到 srcObj 属性的值， 再调用 set 方法将获取到的属性
值赋值给 destObj 的属性
        setMethod.invoke(destObj, getMethod.invoke(srcObj))
      }

    }

  }

}
```

2.3.3 消费 Kafka 数据

```
object DwDDauApp {
  def main(args: Array[String]): Unit = {
    //1.环境
    val          sparkconf:          SparkConf          =          new
SparkConf().setAppName("dwd_dau_app").setMaster("local[4]")
    val ssc = new StreamingContext(sparkconf,Seconds(5))

    val topic = "DWD_PAGE_LOG"
    val groupId = "dwd_dau_group"

    //2.读取偏移量
    val       offsets:       Map[TopicPartition,       Long]       =
MyOffsetUtils.getOffset(topic,groupId)

    //3.接收 Kafka 数据
    var  kafkaDStream:  DStream[ConsumerRecord[String,  String]]  =
null
    if(offsets != null && offsets.nonEmpty ){
      kafkaDStream                                                  =
MyKafkaUtils.getKafkaDStream(topic,ssc,offsets,groupId)
    }else{
      kafkaDStream                                                  =
MyKafkaUtils.getKafkaDStream(topic,ssc,groupId)
    }

    //4. 提取偏移量结束点
    var  offsetRanges: Array[OffsetRange] = null
    kafkaDStream = kafkaDStream.transform(
      rdd => {
        offsetRanges                                                =
rdd.asInstanceOf[HasOffsetRanges].offsetRanges
        rdd
      }
    )
```

```
    //5. 转化结构
    val pageLogDStream: DStream[PageLog] = kafkaDStream.map(
      record => {
        val jsonStr: String = record.value()
        val    pageLog:    PageLog    =    JSON.parseObject(jsonStr,
classOf[PageLog])
        pageLog
      }
    )
pageLogDStream.print(100)
}
}
```

2.3.4 去重

1）分析

日活的统计我们只需要考虑用户的首次访问行为，不同企业判断用户活跃的方式不同，可以通过启动数据或者页面数据来分析，我们采用页面数据来统计日活，页面数据中包含用户所有的访问行为，而我们只需要首次访问行为，所以可以在每批次的数据中先将包含有 last_page_id 的数据过滤掉， 剩下的数据再与第三方（redis）中所记录的今日访问用户进行比对。

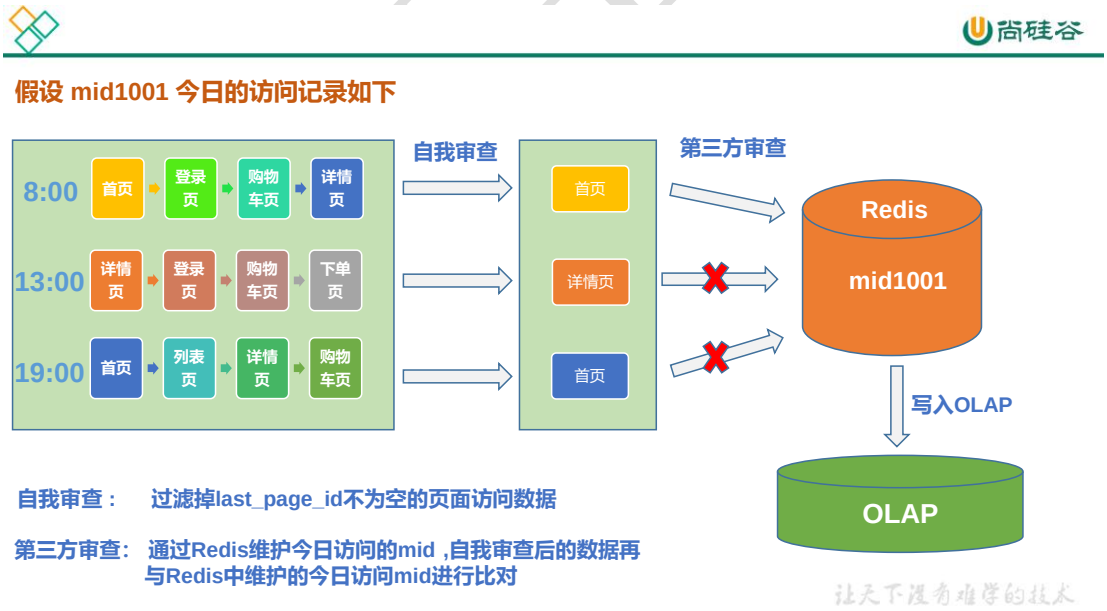

2）代码实现

```
//6.筛选去重
    // 6.1 自我审查 凡是有 last_page_id，说明不是本次会话的第一个页面，直接过滤掉
    val      filterDStreamByLastPage:      DStream[PageLog]      =
pageLogDStream.filter(
      pageLog => {
        pageLog.last_page_id == null
```

```
      }
    )
    // 6.2 第三方审查 所有会话的第一个页面， 去 redis 中检查是否是今天的第一
次
    val pageLogFilterDStream: DStream[PageLog] =
filterDStreamByLastPage.mapPartitions(
      pageLogIter => {
        //获取 redis 连接
        val jedis: Jedis = MyRedisUtils.getJedisClient
        val filterList: ListBuffer[PageLog] =
ListBuffer[PageLog]()
        val pageLogList: List[PageLog] = pageLogIter.toList
        println("过滤前 : " + pageLogList.size)
        for (pageLog <- pageLogList) {
          val sdf = new SimpleDateFormat("yyyy-MM-dd")
          val dateStr: String = sdf.format(new Date(pageLog.ts))
          val dauKey: String = s"DAU:$dateStr"
          val ifNew: lang.Long = jedis.sadd(dauKey, pageLog.mid)
          //设置过期时间
          jedis.expire(dauKey,3600 * 24)
          if (ifNew == 1L) {
            filterList.append(pageLog)
          }
        }
        jedis.close()
        println("过滤后: " + filterList.size)
        filterList.toIterator
      }
    )
    //pageLogFilterDStream.print(10)
```

2.3.5 维度合并

1）分析

由于要针对各种对于不同角度的“日活”分析，而 OLAP 数据库中尽量减少 join 操作，所以在实时计算中要考虑其会被分析的维度，补充相应的维度数据，形成宽表。

由于维度数据已经保存在固定容器中了，所以在实时计算中，维度与事实数据关联并不是通过 join 算子完成。而是在流中查询固定容器（redis/mysql/hbase）来实现维度补充。

用户信息维度关联

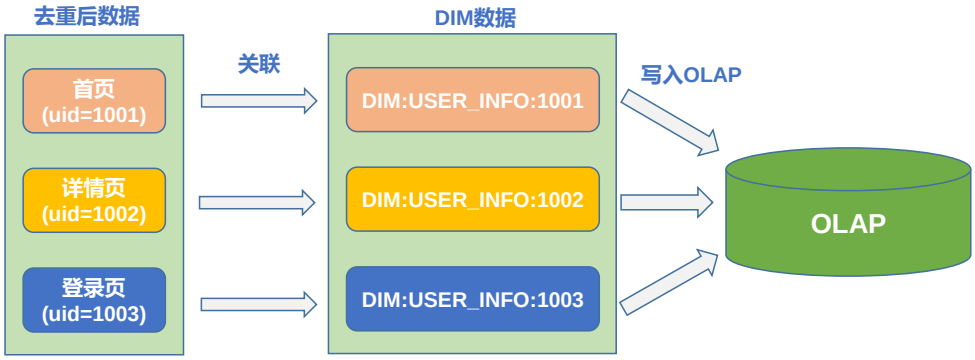

2）代码实现

```
//7. 维度合并
    val          dauInfoDStream:          DStream[DauInfo]          =
pageLogFilterDStream.mapPartitions(
      pageLogIter => {
        val jedis: Jedis = MyRedisUtils.getJedisClient
        val        dauInfoList:        ListBuffer[DauInfo]        =
ListBuffer[DauInfo]()

        for (pageLog <- pageLogIter) {
          //用户信息关联
          val dimUserKey = s"DIM:USER_INFO:${pageLog.user_id}"
          val userInfoJson: String = jedis.get(dimUserKey)
          val         userInfoJsonObj:         JSONObject         =
JSON.parseObject(userInfoJson)
          //提取生日
          val             birthday:             String             =
userInfoJsonObj.getString("birthday")
          //提取性别
          val gender: String = userInfoJsonObj.getString("gender")
          //生日处理为年龄
          var age: String = null
          if (birthday != null) {
            //闰年无误差
            val          birthdayDate:          LocalDate          =
LocalDate.parse(birthday)
            val nowDate: LocalDate = LocalDate.now()
            val  period:  Period  =  Period.between(birthdayDate,
nowDate)
            val years: Int = period.getYears
            age = years.toString
          }

          val dauInfo = new DauInfo()
```

```
          //将 PageLog 的字段信息拷贝到 DauInfo 中
          MyBeanUtils.copyProperties(pageLog, dauInfo)
          dauInfo.user_gender = gender
          dauInfo.user_age = age

          //TODO 地区维度关联
          val provinceKey : String =
s"DIM:BASE_PROVINCE:${pageLog.province_id}"
          val provinceJson: String = jedis.get(provinceKey)
          if(provinceJson!= null && provinceJson.nonEmpty ){
            val provinceJsonObj: JSONObject =
JSON.parseObject(provinceJson)
            dauInfo.province_name =
provinceJsonObj.getString("name")
            dauInfo.province_area_code =
provinceJsonObj.getString("area_code")
            dauInfo.province_3166_2 =
provinceJsonObj.getString("iso_3166_2")
            dauInfo.province_iso_code =
provinceJsonObj.getString("iso_code")
          }

          //日期补充
          val dateFormat = new SimpleDateFormat("yyyy-MM-dd HH")
          val dtDate = new Date(dauInfo.ts)
          val dtHr: String = dateFormat.format(dtDate)
          val dtHrArr: Array[String] = dtHr.split(" ")
          dauInfo.dt = dtHrArr(0)
          dauInfo.hr = dtHrArr(1)

          dauInfoList.append(dauInfo)

        }
        jedis.close()
        dauInfoList.toIterator
      }
    )
  dauInfoDStream.print(100)
```

2.3.6 写入 ES 并提交偏移量

1）建立索引模板

```
PUT   _template/gmall_dau_info_template
{
  "index_patterns": ["gmall_dau_info*"],
  "settings": {
    "number_of_shards": 3
  },
  "aliases" : {
    "{index}-query": {},
    "gmall_dau_info_all":{}
  },
   "mappings": {
       "properties":{
         "mid":{
```

```
        "type":"keyword"
      },
      "user_id":{
        "type":"keyword"
      },
       "province_id":{
        "type":"keyword"
      },
        "channel":{
        "type":"keyword"
      },
       "is_new":{
        "type":"keyword"
      },
       "model":{
        "type":"keyword"
      },
       "operate_system":{
        "type":"keyword"
      },
       "version_code":{
        "type":"keyword"
      },
       "page_id":{
        "type":"keyword"
      },
       "page_item":{
        "type":"keyword"
      },
      "page_item_type":{
        "type":"keyword"
      },
      "during_time":{
        "type":"long"
      },
      "user_gender":{
        "type":"keyword"
      },
       "user_age":{
        "type":"integer"
      },
       "province_name":{
        "type":"keyword"
      },
       "province_iso_code":{
        "type":"keyword"
      },
      "province_3166_2":{
        "type":"keyword"
      },
      "province_area_code":{
        "type":"keyword"
      },
       "dt":{
        "type":"keyword"
      },
```

```
          "hr":{
            "type":"keyword"
          },
          "ts":{
            "type":"date"
          }
        }
    }
}
```

2）ES 工具类

```
package com.atguigu.gmall.realtime.util

import com.alibaba.fastjson.JSON
import com.alibaba.fastjson.serializer.SerializeConfig
import org.apache.http.HttpHost
import org.elasticsearch.action.bulk.BulkRequest
import org.elasticsearch.action.index.IndexRequest
import    org.elasticsearch.client.{RequestOptions,    RestClient,
RestClientBuilder, RestHighLevelClient}
import org.elasticsearch.common.xcontent.XContentType

/**
  * ES 工具类
  */
object MyESUtils {

  //声明 es 客户端
  var esClient : RestHighLevelClient = build()

  /**
    *  批量数据幂等写入
    *  通过指定 id 实现幂等
    */
  def      bulkSaveIdempotent(sourceList:      List[(String      ,
AnyRef)] ,indexName: String ): Unit ={
    if(sourceList!= null && sourceList.nonEmpty){
      // BulkRequest 实际上就是由 7 多个单条 IndexRequest 的组合
      val bulkRequest = new BulkRequest()

      for ((docId,sourceObj) <- sourceList) {
        val indexRequest = new IndexRequest()
        indexRequest.index(indexName)
        val  movieJsonStr:  String  =  JSON.toJSONString(sourceObj,
new SerializeConfig(true))
        indexRequest.source(movieJsonStr,XContentType.JSON)
        indexRequest.id(docId)
        bulkRequest.add(indexRequest)
      }

      esClient.bulk(bulkRequest,RequestOptions.DEFAULT)
    }

  }
  /**
```

```
    *  批量数据写入
    */
  def  bulkSave(sourceList:  List[AnyRef]  ,indexName:  String  ):
Unit ={
    // BulkRequest 实际上就是由多个单条 IndexRequest 的组合
    val bulkRequest = new BulkRequest()

    for (source <- sourceList) {
      val indexRequest = new IndexRequest()
      indexRequest.index(indexName)
      val  movieJsonStr:  String  =  JSON.toJSONString(source,  new
SerializeConfig(true))
      indexRequest.source(movieJsonStr,XContentType.JSON)
      bulkRequest.add(indexRequest)
    }

    esClient.bulk(bulkRequest,RequestOptions.DEFAULT)
  }
  /**
    *  单条数据幂等写入
    *  通过指定 id 实现幂等
    */
  def   saveIdempotent(source:(String   ,   AnyRef),indexName   :
String ): Unit = {
    val indexRequest = new IndexRequest()
    indexRequest.index(indexName)
    val  movieJsonStr:  String  =  JSON.toJSONString(source._2,  new
SerializeConfig(true))
    indexRequest.source(movieJsonStr,XContentType.JSON)
    indexRequest.id(source._1)
    esClient.index(indexRequest,RequestOptions.DEFAULT)
  }
  /**
    *  单条数据写入
    */
  def save(source:AnyRef,indexName : String ): Unit = {
    val indexRequest = new IndexRequest()
    indexRequest.index(indexName)
    val  movieJsonStr:  String  =  JSON.toJSONString(source,  new
SerializeConfig(true))
    indexRequest.source(movieJsonStr,XContentType.JSON)
    esClient.index(indexRequest,RequestOptions.DEFAULT)
  }

  /**
    * 销毁
    */
  def destory(): Unit ={
    esClient.close()
    esClient = null
  }

  /**
    * 创建 es 客户端对象
    */
```

```
  def build():RestHighLevelClient = {
    val builder: RestClientBuilder = RestClient.builder(new
HttpHost("hadoop102",9200))
    val esClient = new RestHighLevelClient(builder)
    esClient
  }

  /**
    * 获取 esclient
    */
  def getClient(): RestHighLevelClient = {
    esClient
  }

}
```

3）业务代码

主程序调用工具类批量写入 ES，其实我们前面已经使用 Redis 进行了去重操作，基本上是可以保证幂等性的。如果更严格的保证幂等性，那我们在批量向 ES 写数据的时候，指定 Index 的 id 即可。

```
// TODO 8.写入 ES
    dauInfoDStream.foreachRDD(
       rdd => {
         rdd.foreachPartition(
           dauInfoIter => {
             // 因为是日活宽表，一天之内 mid 是不应该重复的
             //转换数据结构，保证幂等写入
             val dauInfos: List[(String, DauInfo)] =
dauInfoIter.toList.map(dauInfo => (dauInfo.mid,dauInfo))
             if(dauInfos.size > 0 ){
               //从数据中获取日期，拼接 ES 的索引名
               val dauInfoT: (String, DauInfo) = dauInfos(0)
               val dt = dauInfoT._2.dt

MyESUtils.bulkSaveIdempotent(dauInfos,s"gmall_dau_info_$dt")
             }
           }
         )
         // TODO 9.提交偏移量
         MyOffsetUtils.saveOffset(topic,groupId,offsetRanges)
       }
    )
```

2.4 状态数据还原

2.4.1 问题现象

想象一个比较极端的情况， 如果某个用户某天的首次访问数据写入 redis 后， 接下来在写入到 es 的过程中,程序挂掉。 会出现什么问题？

2.4.2 分析

程序挂掉，偏移量还未提交，重启后会触发数据的重试，但是因为 redis 中记录了相关的数据，所以该数据会被过滤掉。因此此数据，就再也无法进入 es，也就意味着丢失。

这个问题的本质就是，状态数据与最终数据库的数据以及偏移量，没有形成原子性事务造成的。

当然可以通过事务数据库的方式解决该问题，而我们的项目中没有选择使用支持事务的数据库，例如 MySQL 等。在既有的环境下我们依然有很多破解方案，例如进行状态还原，在启动程序前，将 ES 中已有的数据的 mid 提取出来，覆盖到 Redis 中，这样就能保证 Redis 和 ES 数据的同步.

2.4.3 解决方案

1）在 ES 工具类中添加方法

```
/**
    * 查询指定的字段
    */
  def searchField(indexName: String, fieldName: String):
List[String] = {
    //判断索引是否存在
    val getIndexRequest: GetIndexRequest = new
GetIndexRequest(indexName)
    val isExists: Boolean =

esClient.indices().exists(getIndexRequest,RequestOptions.DEFAULT)
    if(!isExists){
      return null
    }
    //正常从 ES 中提取指定的字段
    val mids: ListBuffer[String] = ListBuffer[String]()
    val searchRequest: SearchRequest = new
SearchRequest(indexName)
    val searchSourceBuilder: SearchSourceBuilder = new
SearchSourceBuilder()
    searchSourceBuilder.fetchSource(fieldName,null).size(100000)
    searchRequest.source(searchSourceBuilder)
    val searchResponse: SearchResponse =
        esClient.search(searchRequest , RequestOptions.DEFAULT)
    val hits: Array[SearchHit] = searchResponse.getHits.getHits
    for (hit <- hits) {
      val sourceMap: util.Map[String, AnyRef] =
hit.getSourceAsMap
      val mid: String = sourceMap.get(fieldName).toString
      mids.append(mid)
    }
    mids.toList
  }
```

2）在主程序中添加状态还原方法

```
/**
    * 状态还原
    *
    * 在每次启动实时任务时， 进行一次状态还原。 以 ES 为准，将所以的 mid 提取出来，覆盖到 Redis 中.
    */

  def revertDauState(): Unit ={
    //从 ES 中查询到所有的 mid
    val date: LocalDate = LocalDate.now()
    val indexName : String = s"gmall_dau_info_1018_$date"
    val fieldName : String = "mid"
    val mids: List[ String ] = MyEsUtils.searchField(indexName , fieldName)
    //删除 redis 中记录的状态（所有的 mid）
    val jedis: Jedis = MyRedisUtils.getJedisFromPool()
    val redisDauKey : String = s"DAU:$date"
    jedis.del(redisDauKey)
    //将从 ES 中查询到的 mid 覆盖到 Redis 中
    if(mids != null && mids.size > 0 ){
      /*for (mid <- mids) {
        jedis.sadd(redisDauKey , mid )
      }*/
      val pipeline: Pipeline = jedis.pipelined()
      for (mid <- mids) {
        pipeline.sadd(redisDauKey , mid )  //不会直接到 redis 执行
      }

      pipeline.sync()  // 到 redis 执行
    }

    jedis.close()
  }
```

2）调整 ES 参数

此方法由于需要把当日全部 mid 取出，会受到 es 默认的结果返回数限制。需要修改配置扩大返回结果数，如下：

```
PUT /_settings
{
  "index.max_result_window" :"5000000"
}
```

3）修补主程序，在整个程序加载数据前进行状态还原

```
def main(args: Array[String]): Unit = {

 //0.还原状态
    revertDauState()


    //1.环境
```

```
//2.读取偏移量

//3. ……
```

第 3 章 任务:订单业务宽表

3.1 需求举例

1）订单热力地图

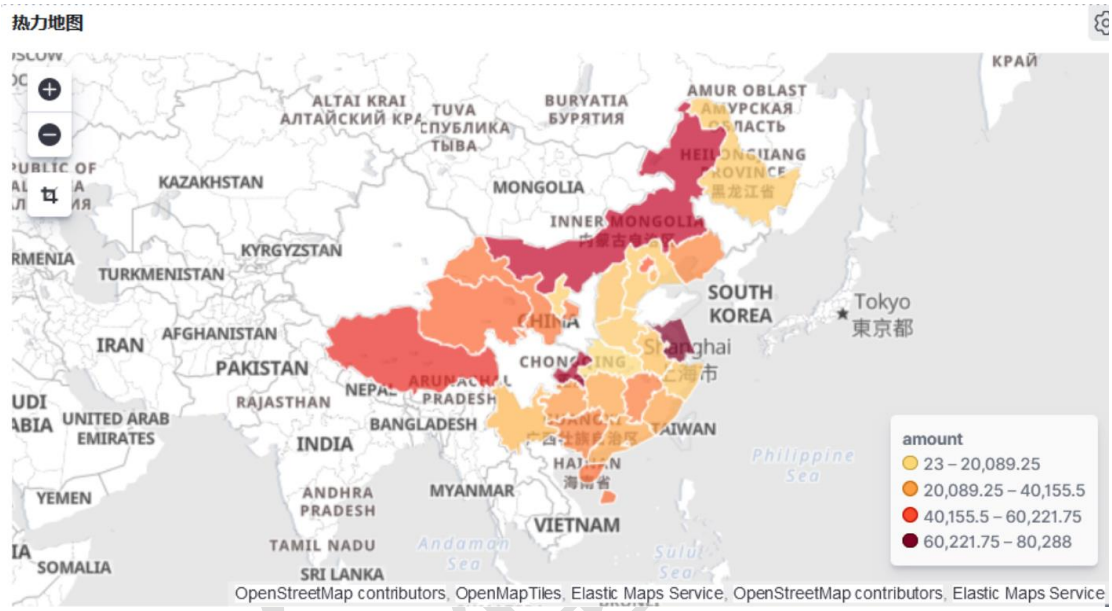

2）订单交易分析

3.2 需求分析

由于在很多 OLAP 数据库对聚合过滤都是非常强大，但是大表间的关联都不是长项。

所以在数据进入 OLAP 前，尽量提前把数据关联组合好，不要在查询的时候临时进行 Join 操作。所谓提前关联好，在实时计算中进行流 Join。

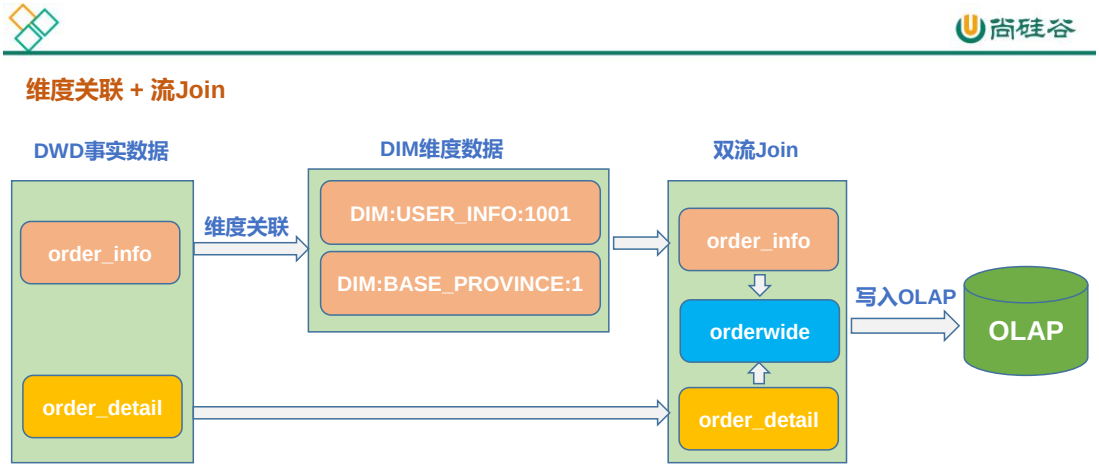

3.2.1 流与维度关联

流与维度表之间的合并, 通常是事实表与维度表之间的关联。

3.2.2 双流 join

流与流之间的合并，也可以叫双流 join，通常是几乎同时产生的事实表的关联。

3.3 功能实现

3.3.1 准备 Bean

1）OrderInfo , 封装订单表数据

```
package com.atguigu.gmall.realtime.bean

case class OrderInfo(
                      id: Long =0L,
                      province_id: Long=0L,
                      order_status: String=null,
                      user_id: Long=0L,
                      total_amount:  Double=0D,
                      activity_reduce_amount: Double=0D,
                      coupon_reduce_amount: Double=0D,
                      original_total_amount: Double=0D,
                      feight_fee: Double=0D,
                      feight_fee_reduce: Double=0D,
                      expire_time: String =null,
                      refundable_time:String =null,
                      create_time: String=null,
```

```
                        operate_time: String=null,
                        var create_date: String=null, // 把其他字段处
理得到
                        var create_hour: String=null,

                        var province_name:String=null,//查询维度表得到
                        var province_area_code:String=null,
                        var province_3166_2_code:String=null,
                        var province_iso_code:String=null,

                        var user_age :Int=0, //查询维度表得到
                        var user_gender:String=null
                      ) {

}
```

2）OrderDetail，封装订单详情数据

```
package com.atguigu.gmall.realtime.bean

case class OrderDetail(
                        id : Long ,
                        order_id :Long ,
                        sku_id : Long ,
                        order_price : Double ,
                        sku_num : Long ,
                        sku_name :String ,
                        create_time : String ,
                        split_total_amount: Double = 0D,
                        split_activity_amount: Double =0D,
                        split_coupon_amount:Double = 0D
                        ) {

}
```

3）OrderWide，订单宽表

```
package com.atguigu.gmall.realtime.bean

import com.atguigu.gmall.realtime.util.MyBeanUtils

case class OrderWide(
                        var  detail_id: Long =0L,
                        var  order_id:Long=0L,
                        var  sku_id: Long=0L,
                        var  order_price: Double=0D,
                        var  sku_num:Long=0L,
                        var  sku_name: String=null,
                        var  split_total_amount:Double=0D,
                        var  split_activity_amount:Double=0D,
                        var  split_coupon_amount:Double=0D,

                        var  province_id: Long=0L,
                        var  order_status: String=null,
                        var  user_id: Long=0L,
                        var  total_amount:  Double=0D,
                        var  activity_reduce_amount: Double=0D,
```

```
                        var  coupon_reduce_amount: Double=0D,
                        var  original_total_amount: Double=0D,
                        var  feight_fee: Double=0D,
                        var  feight_fee_reduce: Double=0D,
                        var  expire_time: String =null,
                        var  refundable_time:String =null,
                        var  create_time: String=null,
                        var operate_time: String=null,
                        var create_date: String=null,
                        var create_hour: String=null,

                        var province_name:String=null,
                        var province_area_code:String=null,
                        var province_3166_2_code:String=null,
                        var province_iso_code:String=null,


                        var user_age :Int=0,
                        var user_gender:String=null

                      ) {

  def this(orderInfo : OrderInfo ,orderDetail: OrderDetail){
    this
    mergeOrderInfo(orderInfo)
    mergeOrderDetail(orderDetail)
  }

  def mergeOrderInfo(orderInfo: OrderInfo): Unit ={
    if(orderInfo != null ){
      MyBeanUtils.copyProperties(orderInfo,this)
      this.order_id = orderInfo.id
    }
  }

  def mergeOrderDetail (orderDetail: OrderDetail): Unit ={
    if(orderDetail != null ){
      MyBeanUtils.copyProperties(orderDetail,this)
      this.detail_id = orderDetail.id
    }
  }
}
```

3.3.2 消费 Kafka 数据

```
object DwDOrderApp {
  def main(args: Array[String]): Unit = {
    //.1 准备环境
    val          sparkconf:          SparkConf          =          new
SparkConf().setAppName("dwd_dau_app").setMaster("local[4]")
    val ssc = new StreamingContext(sparkconf,Seconds(5))

    val orderInfoTopic = "DWD_ORDER_INFO_I"
    val orderDetailTopic  = "DWD_ORDER_DETAIL_I"
    val groupId = "dwd_order_group"
```

```
    //2.读取偏移量
    val    orderInfoOffsets:    Map[TopicPartition,    Long]    =
MyOffsetUtils.getOffset(orderInfoTopic,groupId)
    val    orderDetailOffsets:    Map[TopicPartition,    Long]    =
MyOffsetUtils.getOffset(orderDetailTopic,groupId)

    //3.接收 Kafka 数据
    //order_info
    var    orderInfoKafkaDStream:    DStream[ConsumerRecord[String,
String]] = null
    if(orderInfoOffsets != null && orderInfoOffsets.nonEmpty ){
      orderInfoKafkaDStream                                          =
MyKafkaUtils.getKafkaDStream(orderInfoTopic,ssc,orderInfoOffsets,
groupId)
    }else{
      orderInfoKafkaDStream                                          =
MyKafkaUtils.getKafkaDStream(orderInfoTopic,ssc,groupId)
    }

    //order_detail
    var   orderDeatilKafkaDStream:   DStream[ConsumerRecord[String,
String]] = null
    if(orderDetailOffsets           !=           null           &&
orderDetailOffsets.nonEmpty ){
      orderDeatilKafkaDStream                                        =
MyKafkaUtils.getKafkaDStream(orderDetailTopic,ssc,orderDetailOffs
ets,groupId)
    }else{
      orderDeatilKafkaDStream                                        =
MyKafkaUtils.getKafkaDStream(orderDetailTopic,ssc,groupId)
    }

    //4. 提取偏移量结束点
    //order_info

    var  orderInfoOffsetRanges: Array[OffsetRange] = null
    orderInfoKafkaDStream = orderInfoKafkaDStream.transform(
      rdd => {
        orderInfoOffsetRanges                                        =
rdd.asInstanceOf[HasOffsetRanges].offsetRanges
        rdd
      }
    )

    //order_detail
    var  orderDetailOffsetRanges: Array[OffsetRange] = null
    orderDeatilKafkaDStream = orderDeatilKafkaDStream.transform(
      rdd => {
        orderDetailOffsetRanges                                      =
rdd.asInstanceOf[HasOffsetRanges].offsetRanges
        rdd
      }
    )
```

```
    //5. 转换结构

    val orderInfoDStream: DStream[OrderInfo] =
orderInfoKafkaDStream.map(
      record => {
        val jsonStr: String = record.value()
        val orderInfo: OrderInfo = JSON.parseObject(jsonStr,
classOf[OrderInfo])
        orderInfo
      }
    )

    val orderDetailDStream: DStream[OrderDetail] =
orderDeatilKafkaDStream.map(
      record => {
        val jsonStr: String = record.value()
        val orderDetail: OrderDetail = JSON.parseObject(jsonStr,
classOf[OrderDetail])
        orderDetail
      }
)
}
}
```

3.3.3 维度合并

```
//6.维度合并(补充用户年龄性别 、 地区信息)
    val orderInfoWithDimDStream: DStream[OrderInfo] =
orderInfoDStream.mapPartitions(
      orderInfoIter => {
        val jedis: Jedis = MyRedisUtils.getJedisClient
        val orderInfoList: List[OrderInfo] = orderInfoIter.toList
        for (orderInfo <- orderInfoList) {

          //补充用户信息
          val userInfoKey = s"DIM:USER_INFO:${orderInfo.user_id}"
          val userInfoJson: String = jedis.get(userInfoKey)
          val userInfoJsonObj: JSONObject =
JSON.parseObject(userInfoJson)
          //获取性别
          orderInfo.user_gender =
userInfoJsonObj.getString("gender")
          //获取年龄
          val birthday: String =
userInfoJsonObj.getString("birthday")
          val birthdayDate: LocalDate = LocalDate.parse(birthday)
          val nowDate: LocalDate = LocalDate.now()
          val period: Period = Period.between(birthdayDate,
nowDate)
          val age: Int = period.getYears
          orderInfo.user_age = age

          //补充日期字段
          val dateTimeArr: Array[String] =
orderInfo.create_time.split(" ")
```

```
            orderInfo.create_date = dateTimeArr(0)
            orderInfo.create_hour = dateTimeArr(1).split(":")(0)

            //TODO 补充地区信息

            val     provinceKey     =     "DIM:BASE_PROVINCE:"     +
orderInfo.province_id
            val provinceJson: String = jedis.get(provinceKey)
            val         provinceJsonObj:         JSONObject         =
JSON.parseObject(provinceJson)
            orderInfo.province_name                                    =
provinceJsonObj.getString("name")
            orderInfo.province_area_code                               =
provinceJsonObj.getString("area_code")  //  ali  datav    quickbi
baidu suger
            orderInfo.province_3166_2_code                             =
provinceJsonObj.getString("iso_3166_2") // kibana
            orderInfo.province_iso_code                                =
provinceJsonObj.getString("iso_code") // superset

          }

          jedis.close()
          orderInfoList.toIterator
        }
    )
```

3.3.4 双流 join

1）分析

由于两个流的数据是独立保存，独立消费，很有可能同一业务的数据，分布在不同的批次。因为 join 算子只 join 同一批次的数据。如果只用简单的 join 流方式，会丢失掉不同批次的数据。

2）解决策略

（1）增大采集周期

（2）利用滑动窗口进行 join 然后再进行去重

（3）**把数据存入缓存 ，关联时进行 join 后 ，再去查询缓存中的数据，来弥补不同批次的问题。**

3）程序流程图（缓存策略）

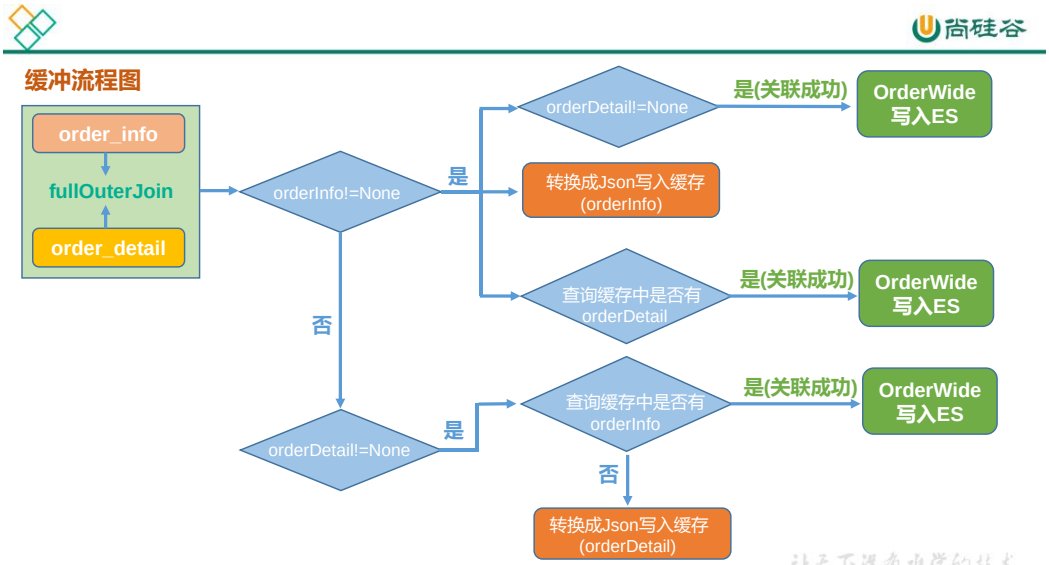

4）代码实现

```
//双流 join
    // 如果要做 Join 操作，必须是 DStream[K,V] 和 DStream[K,V]
    val orderInfoWithKeyDStream: DStream[(Long, OrderInfo)] =
      orderInfoWithDimDStream.map(orderInfo                    =>
(orderInfo.id,orderInfo))

    val orderDetailWithKeyDStream: DStream[(Long, OrderDetail)] =
      orderDetailDStream.map(            orderDetail            =>
(orderDetail.order_id,orderDetail))

    //join 只能实现统一批次的数据进行 Join,如果有数据延迟，延迟的数据就不能
jion 成功， 就会有数据丢失.
    //val joinDStream: DStream[(Long, (OrderInfo, OrderDetail))]
= orderInfoWithKeyDStream.join(orderDetailWithKeyDStream)
    //joinDStream.print(1000)

    //通过状态或者缓存来解决。

    val   orderJoinDStream:   DStream[(Long,   (Option[OrderInfo],
Option[OrderDetail]))] =

orderInfoWithKeyDStream.fullOuterJoin(orderDetailWithKeyDStream)

    val        orderWideDStream:        DStream[OrderWide]        =
orderJoinDStream.flatMap {
      case (orderId, (orderInfoOpt, orderDetailOpt)) => {
        val       orderWideList:       ListBuffer[OrderWide]       =
ListBuffer[OrderWide]()
        val jedis: Jedis = MyRedisUtils.getJedisClient
        //1.主表在
        if (orderInfoOpt != None) {
          val orderInfo: OrderInfo = orderInfoOpt.get
          //1.1 判断从表是否存在
```

```
          if (orderDetailOpt != None) {
            //如果从表在， 将主和从合并
            val orderDetail: OrderDetail = orderDetailOpt.get
            val orderWide = new OrderWide(orderInfo, orderDetail)
            orderWideList.append(orderWide)
          }

          //1.2 主表写缓存
          //type: String
          //key : ORDER_JOIN:ORDER_INFO:[ID]
          //value : orderInfoJson
          //写入 API: set
          //读取 API: get
          //过期时间: 小时~天  24 小时
          val                    orderInfoKey                    =
s"ORDER_JOIN:ORDER_INFO:${orderInfo.id}"
          val orderInfoJson: String = JSON.toJSONString(orderInfo,
new SerializeConfig(true))
          jedis.setex(orderInfoKey, 3600 * 24, orderInfoJson)

          //1.3 主表读缓存
          // type : set
          // key : ORDER_JOIN:ORDER_DETAIL:[ORDERID]
          // value : orderDetailJson
          //写入 API: sadd
          //读取 API: smembers
          //过期时间： 小时~天 24 小时
          val                  orderDetailKey                    =
s"ORDER_JOIN:ORDER_DETAIL:${orderInfo.id}"
          val      orderDetaiJsonSet:      util.Set[String]      =
jedis.smembers(orderDetailKey)
          import scala.collection.JavaConverters._
          if       (orderDetaiJsonSet       !=       null       &&
orderDetaiJsonSet.size() > 0) {
            for (orderDetailJson <- orderDetaiJsonSet.asScala) {
              val        orderDetail:        OrderDetail        =
JSON.parseObject(orderDetailJson, classOf[OrderDetail])
              val    orderWide    =    new    OrderWide(orderInfo,
orderDetail)
              orderWideList.append(orderWide)
            }

          }
        } else {
          //2. 主表不在，从表在
          val orderDetail: OrderDetail = orderDetailOpt.get
          //2.1 从表读缓存
          val                    orderInfoKey                    =
s"ORDER_JOIN:ORDER_INFO:${orderDetail.order_id}"
          val orderInfoJson: String = jedis.get(orderInfoKey)
          if (orderInfoJson != null && orderInfoJson.nonEmpty) {
            val          orderInfo:          OrderInfo          =
JSON.parseObject(orderInfoJson, classOf[OrderInfo])
            val orderWide = new OrderWide(orderInfo, orderDetail)
```

```
            orderWideList.append(orderWide)
          }

          //2.2 从表写缓存
          val                    orderDetailKey                    =
s"ORDER_JOIN:ORDER_DETAIL:${orderDetail.order_id}"
          val          orderDetailJson:          String          =
JSON.toJSONString(orderDetail, new SerializeConfig(true))
          jedis.sadd(orderDetailKey, orderDetailJson)
          jedis.expire(orderDetailKey, 3600 * 24)
        }

        jedis.close()
        orderWideList
      }
    }
    orderWideDStream.print(100)
```

3.3.5 写入 ES 并提交偏移量

1）建索引模板

```
PUT  _template/gmall_order_wide_template
{
   "index_patterns": ["gmall_order_wide*"],
    "settings": {
      "number_of_shards": 3
    },
    "aliases" : {
      "{index}-query": {},
      "gmall_order_wide-query":{}
    },
    "mappings" : {
        "properties" : {
          "detail_id" : {
            "type" :   "keyword"
          },
          "order_id" : {
            "type" : "keyword"
          },
           "sku_id" : {
                "type" : "keyword"
          },
           "sku_num" : {
            "type" : "long"
          },
           "sku_name" : {
            "type" : "text",
            "analyzer": "ik_max_word"
          },
          "order_price" : {
            "type" : "float"
          },
           "split_total_amount" : {
            "type" : "float"
          },
```

```
          "split_activity_amount" : {
            "type" : "float"
          },
          "split_coupon_amount" : {
            "type" : "float"
          },
          "province_id" : {
            "type" : "keyword"
          },
          "order_status" : {
            "type" : "keyword"
          },
          "user_id" : {
            "type" : "keyword"
          },
          "total_amount" : {
            "type" : "float"
          },
          "activity_reduce_amount" : {
            "type" : "float"
          },
          "coupon_reduce_amount" : {
            "type" : "float"
          },
          "original_total_amount" : {
            "type" : "float"
          },
          "feight_fee" : {
            "type" : "float"
          },
          "feight_fee_reduce" : {
            "type" : "float"
          },
          "expire_time" : {
            "type" : "date" ,
            "format" : "yyyy-MM-dd HH:mm:ss"

          },
          "refundable_time" : {
            "type" : "date" ,
            "format" : "yyyy-MM-dd HH:mm:ss"

          },
          "create_time" : {
            "type" : "date" ,
            "format" : "yyyy-MM-dd HH:mm:ss"
          },
          "operate_time" : {
            "type" : "date" ,
            "format" : "yyyy-MM-dd HH:mm:ss"
          },
          "create_date" : {
            "type" : "keyword"
          },
          "create_hour" : {
            "type" : "keyword"
```

```
          },
          "province_name" : {
            "type" : "keyword"
          },
          "province_area_code" : {
            "type" : "keyword"
          },
          "province_3166_2_code" : {
            "type" : "keyword"
          },
           "province_iso_code" : {
            "type" : "keyword"
          },
           "user_age" : {
            "type" : "long"
          },
          "user_gender" : {
            "type" : "keyword"
          }

        }
    }
  }
```

2）保存 ES 代码

```
  //写入 es
    orderWideDStream.foreachRDD(
      rdd => {
        //driver
        rdd.foreachPartition(
          orderWideIter => {
            //executor
            val orderWideList: List[(String, OrderWide)] =
              orderWideIter.toList.map(orderWide                =>
(orderWide.detail_id.toString , orderWide))
            if(orderWideList.size > 0 ){
              val    orderWideT:    (String    ,    OrderWide)    =
orderWideList(0)
              val dt: String = orderWideT._2.create_date
              val indexName = s"gmall_order_wide_$dt"

MyESUtils.bulkSaveIdempotent(orderWideList,indexName)

            }
          }
        )
        //提交偏移量
        MyOffsetUtils.saveOffset(orderInfoTopic,groupId          ,
orderInfoOffsetRanges)

MyOffsetUtils.saveOffset(orderDetailTopic,groupId,orderDetailOffs
etRanges)
       }
    )
```

第 4 章 总结